Warum KI nicht dazulernen kann, ohne zu vergessen

Ein mathematischer Beweis – allgemeinverständlich erklärt

Andreas Bean

April 2026

Das Problem in einem Satz

Jedes Mal, wenn eine Künstliche Intelligenz etwas Neues lernt, vergisst sie zwangsläufig einen Teil dessen, was sie vorher wusste. Das ist kein Fehler in der Software. Es ist **mathematisch unvermeidlich**.

Wie eine KI „weiß“

Stellen Sie sich ChatGPT oder ein anderes Sprachmodell vor. Es besteht aus Milliarden von Zahlen – sogenannten **Parametern** – die während des Trainings eingestellt werden. Diese Zahlen bestimmen, wie das Modell auf eine Frage antwortet.

Wenn das Modell „weiß“, dass Wien die Hauptstadt von Österreich ist, dann bedeutet das: irgendwo in diesen Milliarden Zahlen gibt es ein **Muster**, das genau diese Information speichert.

Mathematisch ausgedrückt: das Wissen ist ein **Fixpunkt** im System. Wenn man dem Modell „Wien“ gibt, kommt „Hauptstadt von Österreich“ zurück – und das Ergebnis bleibt stabil. Wie eine Kugel, die in eine Mulde gerollt ist und dort liegen bleibt.

Jedes Stück Wissen ist eine Mulde in einer Landschaft.
Das gesamte Wissen des Modells ist die Landschaft selbst.

Diese Landschaft – die Gesamtheit aller Mulden – nennen wir das **implizite Connectome**. Es ist nirgends explizit aufgeschrieben, sondern verteilt über alle Milliarden Parameter.

Um den Unterschied zu verstehen, hilft ein Vergleich mit dem menschlichen Gehirn.

Im Gehirn ist Wissen an bestimmten **Orten** gespeichert. Neurowissenschaftler können mit bildgebenden Verfahren (fMRI, EEG) beobachten, welche Gehirnregion aktiv ist, wenn jemand an „Wien“ denkt. Man kennt die Neuronen, man kennt die Verbindungen zwischen ihnen (die **Synapsen**), und man kann die Struktur dieses Netzwerks – das **Connectome** – zumindest im Prinzip kartieren.

Die Landkarte des Wissens ist – zumindest grob – bekannt.

Bei einem Transformer wie GPT-4 ist das **fundamental anders**:

- Die „Mulden“ (Attraktoren) sind nirgends einzeln gespeichert. Sie **entstehen** erst durch das Zusammenspiel aller Milliarden Parameter gleichzeitig.
- Man kann nicht nachschauen, welche Parameter für „Wien = Hauptstadt“ zuständig sind. Das Wissen steckt in einem globalen Muster, das über das gesamte Netzwerk verteilt ist.
- Um die Position auch nur *eines* Attraktors zu berechnen, müsste man eine hochdimensionale nichtlineare Gleichung lösen – in einem Raum mit Tausenden von Dimensionen. Das ist, als müsste man einen bestimmten Stern finden, ohne den Himmel sehen zu können.

Menschliches Gehirn	**Transformer (GPT-4 etc.)**
Neuronen haben feste Positionen	Wissen hat keine lokalisierbare Position
Connectome ist im Prinzip kartierbar	Connectome ist implizit und versteckt
Man weiß, wo das Wissen liegt	Kein Algorithmus kann das herausfinden
Wissen ist *lokalisiert*	Wissen ist *global verteilt*

Das ist der entscheidende Punkt: Im Gehirn kann man theoretisch eine Landkarte zeichnen und sagen „diesen Bereich nicht verändern“. Bei einem Transformer gibt es **keine solche Landkarte**. Und genau deshalb kann man das Wissen nicht schützen, wenn man die Parameter verändert.

Nehmen wir an, das Modell soll ein neues Faktum lernen: „Graz hat 300.000 Einwohner.“

Dazu muss man die Parameter verändern – also einige der Milliarden Zahlen anpassen. Dadurch entsteht eine neue Mulde in der Landschaft (das neue Wissen).

Das Problem: Wenn man die Landschaft verändert, um eine neue Mulde zu graben, verschiebt man automatisch auch alle anderen Mulden. Manche werden flacher, manche verschwinden ganz.

Eine neue Mulde graben, ohne die bestehenden zu verändern,
ist mathematisch unmöglich – fast immer.

In der Fachwelt heißt das **Catastrophic Forgetting** (katastrophales Vergessen). Bisher dachte man, das sei ein technisches Problem, das man mit besseren Algorithmen lösen könnte.

Was der Beweis zeigt

Das Theorem[1] beweist, dass es **kein** Update-Verfahren geben *kann*, das neues Wissen hinzufügt und gleichzeitig alles alte Wissen erhält – es sei denn, das Verfahren kennt *alle*

[1] Bean, A. (2026). *Structural Impossibility of Incremental Concept Learning in Attractor-Based Neural Architectures.* Zenodo. https://doi.org/10.5281/zenodo.15081880

bestehenden Mulden im Voraus.

Es gibt zwei Fälle:

1. **Viel Wissen, wenig Platz:** Wenn das Modell schon mehr Konzepte gelernt hat, als es Freiheitsgrade zum Anpassen gibt, dann ist es *mathematisch unmöglich*, alle alten Konzepte zu erhalten. Nicht schwierig. Unmöglich. Für *jedes* Verfahren.
2. **Noch Platz vorhanden:** Selbst wenn theoretisch genug Freiheitsgrade vorhanden sind, gelingt die Erhaltung nur in extrem seltenen Spezialfällen – so selten, dass sie in einem mathematisch präzisen Sinn "Wahrscheinlichkeit Null" haben.

Die überraschende Parallele zur Quantenphysik

Das Erstaunlichste an diesem Ergebnis ist, dass es ein bekanntes Problem aus der Quantenphysik *exakt* widerspiegelt. Das ist keine lose Metapher – die mathematische Struktur ist dieselbe.

Kurz erklärt: Was ist Quantenfehlerkorrektur?

Quantencomputer rechnen mit **Qubits** – winzigen Systemen, die gleichzeitig 0 und 1 sein können. Aber Qubits sind extrem empfindlich: jede Störung von außen (Wärme, Strahlung, sogar ein vorbeifliegendes Photon) kann die gespeicherte Information zerstören.

Um dem entgegenzuwirken, gibt es die **Quantenfehlerkorrektur**. Dabei verteilt man die Information auf viele Qubits gleichzeitig und schützt sie in einem **Codespace** – einem mathematisch definierten „sicheren Bereich" im Quantenzustand. Diesen Codespace nennt man P_C.

Die Physiker Knill und Laflamme haben 1997 **exakte Bedingungen** hergeleitet, wann Fehlerkorrektur möglich ist. Die sogenannten **Knill-Laflamme-Bedingungen** besagen im Wesentlichen:

Man kann Fehler nur dann korrigieren,
wenn man den Codespace P_C kennt.

Ohne Kenntnis von P_C ist es *unmöglich*, ein Fehlerkorrektur-Protokoll zu entwerfen – egal wie clever man vorgeht. Das ist kein technisches Versagen, sondern ein mathematisches Gesetz.

Die Verbindung

Jetzt die entscheidende Beobachtung: In unserem Theorem taucht **exakt dasselbe Problem** auf, nur in anderer Verkleidung.

Wenn man bei einem Transformer die Parameter ändert, um neues Wissen hinzuzufügen, muss man ein Gleichungssystem lösen, um die alten Attraktoren zu erhalten. Aber die Koeffizienten dieses Gleichungssystems hängen von den *Positionen der Attraktoren* ab – also von genau der Information, die man nicht hat.

Das ist *strukturell identisch* mit dem Quantenproblem:

Quantenfehlerkorrektur	**KI-Sprachmodell**
Information ist im **Codespace** P_C gespeichert	Wissen ist im **impliziten Connectome** gespeichert
Störung = Rauschen, das auf Qubits wirkt	Störung = Parameter-Update, das Attraktoren verschiebt
Fehlerkorrektur braucht Kenntnis von P_C (Knill-Laflamme)	Wissenserhaltung braucht Kenntnis aller Attraktoren
P_C ist global über alle Qubits verteilt, nicht lokal ablesbar	Connectome ist global über alle Parameter verteilt, nicht lokal ablesbar
Ohne P_C: **Fehlerkorrektur unmöglich**	Ohne Connectome: **Wissenserhaltung unmöglich**

Der springende Punkt: In beiden Fällen existiert die zu schützende Struktur *eindeutig* – der Quantencode ist durch die Hardware festgelegt, das Connectome ist durch die Parameter festgelegt. Aber in beiden Fällen ist diese Struktur **versteckt**: Sie lässt sich nicht effizient auslesen.

Das implizite Connectome spielt also *exakt die Rolle des Quantencodes*: Es ist der verborgene, globale Schlüssel, ohne den keine sichere Operation möglich ist.

Warum das bemerkenswert ist

Dass zwei so unterschiedliche Gebiete – Quantenphysik und maschinelles Lernen – auf *dieselbe* mathematische Barriere stoßen, ist kein Zufall. Es deutet auf ein tiefes Prinzip hin:

Wenn Information global und implizit gespeichert ist,
kann sie nicht lokal und blind geschützt werden.
Das gilt für Quantenzustände.
Das gilt für neuronale Netze.

Was bedeutet das für ChatGPT & Co.?

- **Kein noch so cleverer Algorithmus** kann das Problem lösen. Es ist keine Frage der Rechenleistung oder des Trainingsbudgets.
- **Neues Wissen einfügen** (z. B. aktuelle Nachrichten) geht nur durch komplettes Neutraining – genau das, was OpenAI, Google und Anthropic heute alle paar Monate tun.
- **Die Grenze ist strukturell**, nicht technisch. Ähnlich wie die Lichtgeschwindigkeit in der Physik: man kann sich ihr nähern, aber nie überschreiten.
- **Continual Learning** – die Idee, dass eine KI laufend dazulernt wie ein Mensch – ist in der aktuellen Architektur prinzipiell unmöglich, nicht bloß schwierig.

Ein Satz zum Mitnehmen

Die KI hat genau eine Wissenslandschaft.

Sie ist vollständig durch ihre Parameter bestimmt,
aber nirgends explizit ablesbar.

Und ohne sie zu kennen, kann man sie nicht schützen.

Unterzeichner **Andreas Bean**

Datum und Uhrzeit **03.04.2026, 23:08 (GMT+02:00)**

ID Austria

Dieses Dokument ist digital signiert

Dieses mit einer qualifizierten elektronischen Signatur versehene Dokument hat gemäß Art. 25 Abs. 2 der Verordnung (EU) Nr. 910/2014 vom 23. Juli 2014 ("EIDAS-VO") die gleiche Rechtswirkung wie ein handschriftlich unterschriebenes Dokument.

Informationen zur Prüfung der elektronischen Signatur finden Sie unter: https://www.signaturpruefung.gv.at

Preprint: https://doi.org/10.5281/zenodo.15081880 **Kontakt:** Andreas Bean, Graz, Österreich